Classificação de Imagens de Tecido Pulmonar Tomagrafia Computadorizada

Lilian Miranda Mendes, GRR: 20222549
Mozart Gustavo da Cruz Dias, GRR: 20213396
Trabalho desenvolvido para a disciplina de CI1172 - Processamento de Imagens Biomédicas
Departamento de Informática (DINF), Universidade Federal do Paraná (UFPR)

***Resumo*—Este trabalho desenvolve e avalia um pipeline computacional automatizado para a classificação de padrões de tecido pulmonar em imagens de Tomografia Computadorizada (TC) com base em radiômica. A metodologia executa a segmentação automática da região de interesse através do método de Otsu, seguida pela extração de características de textura e primeira ordem com a biblioteca PyRadiomics. Um classificador K-Nearest Neighbors (KNN) foi treinado com os dados extraídos, e sua performance foi avaliada por um protocolo de validação cruzada de 5-folds. O desempenho do sistema foi quantificado por meio das métricas de sensibilidade, especificidade e F1-Score, cujos resultados validam a eficácia do pipeline como um método objetivo para a análise e classificação automática de imagens médicas.**

***Palavras-chave*—Radiômica, Aprendizado de Máquina, Classificação de Imagens, Tomografia Computadorizada, K-Nearest Neighbors.**

I. Introdução

A classificação automática de padrões em imagens de Tomografia Computadorizada (TC) de pulmão é um desafio no diagnóstico médico auxiliado por computador. Este trabalho propõe um pipeline computacional completo para abordar esse problema, utilizando a radiômica para extrair características quantitativas que descrevem os tecidos. A metodologia emprega uma abordagem totalmente automatizada, que inclui a segmentação das regiões de interesse com o método de Otsu, a extração de um vetor de características com a biblioteca Pyradiomics e, por fim, a classificação dos achados por meio do algoritmo K-Nearest Neighbors (KNN). O objetivo principal é avaliar a viabilidade e o desempenho deste fluxo de trabalho, utilizando um protocolo de validação cruzada de 5-folds e métricas de sensibilidade, especificidade e F1-Score para quantificar a capacidade do modelo em distinguir entre diferentes padrões de imagens.

II. Metodologia

A metodologia adotada para a construção do pipeline automático foi dividida em quatro etapas principais: Estratificação e divisão dos dados em folds; Segmentação das regiões de interesse (ROI) nas imagens; Extração de um vetor de características; e Treinamento e avaliação de um modelo de aprendizado de máquina. Essas etapas serão detalhadas nesta seção.

A. *Estratificação e Divisão dos Dados em Folds*

Com base no conjunto de dados fornecido, foi utilizado uma estratégia de estratificação customizada para assegurar uma distribuição mais equilibrada dos pacientes, especialmente para as classes com menor número de amostras. O processo seguiu os seguintes passos:

*1) **Contagem e Ordenação**:* Inicialmente, foi realizada a contagem do número de pacientes pertencentes a cada uma das classes. As classes foram então ordenadas de forma crescente com base nessa contagem, da menos representada para a mais representada, ou seja, da que possuia a maior quantidade de amostrar para a que possuia menos.

*2) **Distribuição Sequencial**:* Uma lista única de pacientes foi criada seguindo a ordem das classes previamente estabelecida. Em seguida, os pacientes foram distribuídos de forma sequencial e cíclica entre os 5 folds. Essa abordagem garantiu que as classes minoritárias fossem distribuídas no início do processo, mitigando o risco de um fold não conter amostras de uma classe específica.

*3) **Verificação**:* Após a distribuição, foram gerados relatórios para cada fold, detalhando o número total de pacientes e a distribuição de pacientes por classe, para verificar o resultado da estratificação. A implementação desses relatórios foi feita por meio de um script **bash**.

B. *Segmentação das Regiões de Interesse (ROI) nas Imagens*

A extração de características radiômicas requer a segmentação prévia da Região de Interesse (ROI) em cada imagem. Para automatizar esta etapa, garantindo objetividade, foi implementado o **método de limiarização de Otsu**. Este processo foi gerenciado pela classe **DataManager** e utilizou a biblioteca **SimpleITK**. Para cada imagem, o algotirmo de Otsu foi aplicado para determinar um limiar ótimo que separa os pixels da imagem em dois grupos (objeto e fundo) com base em seu histograma de intensidade. Isso resultou na criação de uma máscara de segmentação binária para cada imagem original. As máscaras geradas foram salvas no formato NIIfTI(.nii.gz) para o seu uso na etapa seguinte.

C. *Extração de um Vetor de Características*

A extração de um conjunto abrangente de características das imagens foi realizada utilizando a biblioteca **PyRadiomics**. Este processo foi realizado pela classe **RadiomicsExtractor**, que processou cada par de imagem e sua respectiva máscara

de segmentação gerada na etapa anterior. As seguintes classes de características foram extraídas para cada ROI:

- First Order Statistics (Estatísticas de Primeira Ordem).
- Gray Level Co-occurance Matrix (GLCM)
- Gray Level Size Zone Matrix (GLSZM)
- Gray Level Dependence Matrix (GLDM)
- Gray Level Run Length Matrix (GLRLM)
- Neighbouring Gray Tone Difference Matrix (NGTDM)

As características de forma (shape e shape2D) foram desativadas na configuração. O resultado dessa etapa foi um banco de dados salvo em formato **.csv**, contendo os vetores de características para todas as imagens, juntamente com metadados como **patient id**, **class label** e **fold**.

D. Treinamento e Avaliação de um Modelo de Aprendizado de Máquina

A etapa final do pipeline consistiu no treinamento e avaliação de um modelo de aprendizado de máquina para classificar as imagens com base em suas características radiômicas.

*1) **Pré-processamento dos Dados**:* Antes do treinamento, as características radiômicas foram normalizadas utilizando o **StandardScaler** da biblioteca **Scikit-learn**. Este passo garante que todas as características tenham média zero e desvio padrão unitário, evitando que características com escalas maiores dominem o processo de aprendizado.

*2) **Modelo de Classificação**:* O algoritmo **K-Nearest Neighbors (KNN)** foi escolhido para a parte de classificação, configurado com um número de 5 vizinhos.

*3) **Protocolo de Avaliação**:* A performance do modelo foi avaliada seguindo o processo de validação cruzada de 5 folds definido na primeira etapa. Em cada uma das 5 iterações, um fold foi utilizado como conjunto de teste e os quatro restantes como conjunto de treino.

*4) **Métricas de Desempenho**:* Para quantificar a performance do classificador, as seguintes métricas foram calculadas para cada classe em cada fold:

- **Precisão, Sensibilidade (Recall) e F1-Score**, obtidos por meio do **classification report** do Scikit-learn.
- **Especificidade**, calculada manualmente a partir dos componentes da matriz de confusão.

Os resultados finais do modelo foram consolidados calculando-se a média de cada uma dessas métricas ao longo dos cinco folds. Adicionalmente, as matrizes de confusão de cada fold foram visualizadas utilizando as bibliotecas **Matplotlib** e **Seaborn** para uma análise qualitativa dos erros e acertos do modelo.

III. Resultados Obtidos

A seguir, apresentamos os resultados obtidos utilizando o algoritmo do vizinho mais próximo (KNN). Cada tabela resume o desempenho do fold, avaliado com validação cruzada de 5 folds. As métricas representam a média de desempenho para cada classe.

Tabela I
Resultados obtidos no Fold 1.

Classe	Precisão	Recall	F1-Score	Support
Classe 0 (non-lung)	0.98	0.98	0.98	563
Classe 1 (normal)	0.41	0.87	0.56	164
Classe 2 (enfisema)	0.00	0.00	0.00	58
Classe 3 (vidro fosco)	0.70	0.43	0.54	394
Classe 4 (fibrose)	0.85	0.79	0.82	450
Classe 5 (micronódulos)	0.44	0.50	0.46	263
Acurácia Geral			**0.72**	**1892**

Tabela II
Resultados obtidos no Fold 2.

Classe	Precisão	Recall	F1-Score	Support
Classe 0 (non-lung)	0.98	0.98	0.98	453
Classe 1 (normal)	0.55	0.77	0.64	502
Classe 2 (enfisema)	0.00	0.00	0.00	3
Classe 3 (vidro fosco)	0.59	0.93	0.72	275
Classe 4 (fibrose)	0.94	0.75	0.83	973
Classe 5 (micronódulos)	0.96	0.87	0.91	2198
Acurácia Geral			**0.84**	**4404**

Tabela III
Resultados obtidos no Fold 3.

Classe	Precisão	Recall	F1-Score	Support
Classe 0 (non-lung)	0.96	0.97	0.97	466
Classe 1 (normal)	0.72	0.80	0.76	431
Classe 2 (enfisema)	0.00	0.00	0.00	153
Classe 3 (vidro fosco)	0.85	0.42	0.56	503
Classe 4 (fibrose)	0.62	0.87	0.73	181
Classe 5 (micronódulos)	0.84	0.97	0.90	1803
Acurácia Geral			**0.82**	**3537**

Tabela IV
Resultados obtidos no Fold 4.

Classe	Precisão	Recall	F1-Score	Support
Classe 0 (non-lung)	1.00	0.99	0.99	488
Classe 1 (normal)	0.74	0.69	0.72	815
Classe 2 (enfisema)	0.00	0.00	0.00	19
Classe 3 (vidro fosco)	0.64	0.67	0.66	498
Classe 4 (fibrose)	0.54	0.65	0.59	246
Classe 5 (micronódulos)	0.71	0.70	0.70	857
Acurácia Geral			**0.73**	**2923**

Tabela V
Resultados obtidos no Fold 5.

Classe	Precisão	Recall	F1-Score	Support
Classe 0 (non-lung)	1.00	0.99	0.99	553
Classe 1 (normal)	0.90	0.61	0.73	1490
Classe 2 (enfisema)	0.00	0.00	0.00	111
Classe 3 (vidro fosco)	0.51	0.75	0.60	263
Classe 4 (fibrose)	0.14	0.59	0.23	112
Classe 5 (micronódulos)	0.38	0.59	0.46	200
Acurácia Geral			**0.69**	**2729**

Tabela VI
MÉTRICAS FINAIS CONSOLIDADAS (MÉDIA DOS 5 FOLDS).

Classe	Precisão	Recall	Especificidade	F1-Score
Classe 0 (non-lung)	0.98	0.98	1.00	0.98
Classe 1 (normal)	0.66	0.75	0.92	0.68
Classe 2 (enfisema)	0.00	0.00	0.99	0.00
Classe 3 (vidro fosco)	0.66	0.64	0.95	0.62
Classe 4 (fibrose)	0.62	0.73	0.94	0.64
Classe 5 (micronódulos)	0.66	0.72	0.89	0.69

A. *Desempenho Geral*

A acurácia geral do modelo variou entre 70% e 85% ao longo dos folds, indicando um desempenho razoável, porém instável. A Classe 0 (**non-lung**) obteve um F1-Score médio de 0.98, confirmando a alta capacidade do modelo em distingui-la. Em forte contraste, a Classe 2 (**enfisema**) apresentou um F1-Score de 0.00. Este resultado é atribuído ao desbalanceamento de classes, evidenciado pelo baixo número de amostras de suporte (ex: apenas 3 no Fold 2), o que impossibilitou o aprendizado de padrões para esta categoria. As demais classes (**normal, vidro fosco, fibrose e micronódulos**) alcançaram F1-Scores medianos, variando de 0.62 a 0.69.

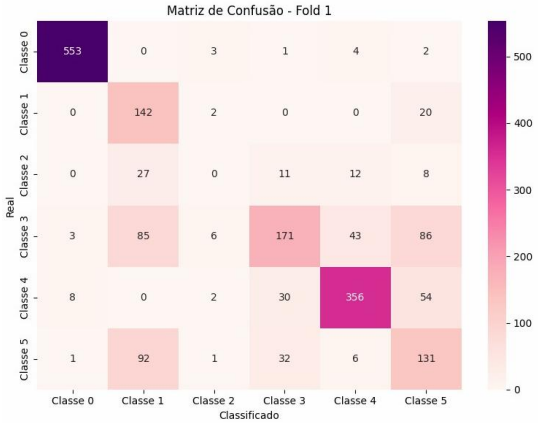

Figura 1. Matriz de confusão com os resultados obtidos no fold 1.

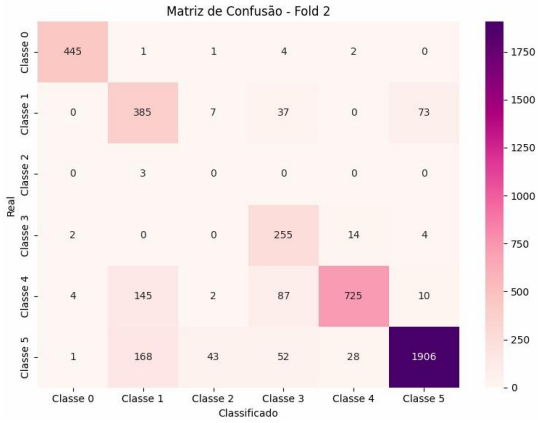

Figura 2. Matriz de confusão com os resultados obtidos no fold 2.

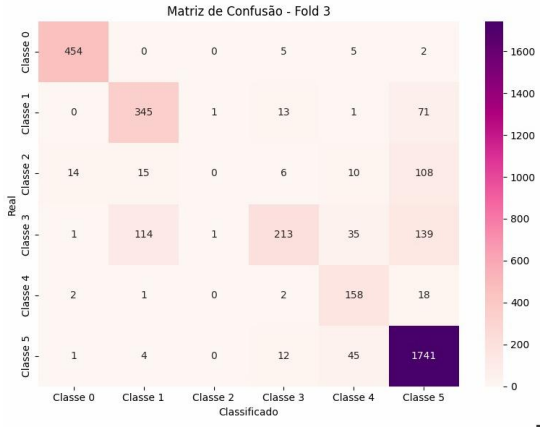

Figura 3. Matriz de confusão com os resultados obtidos no fold 3.

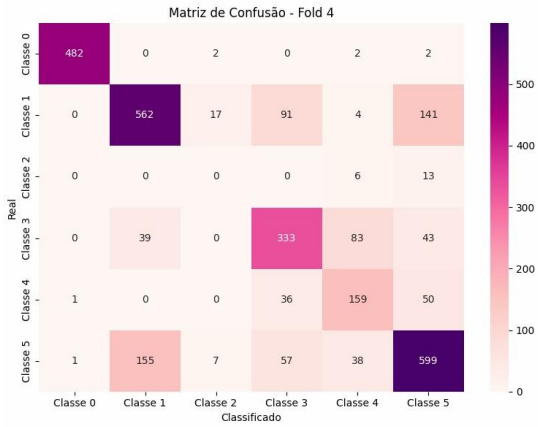

Figura 4. Matriz de confusão com os resultados obtidos no fold 4.

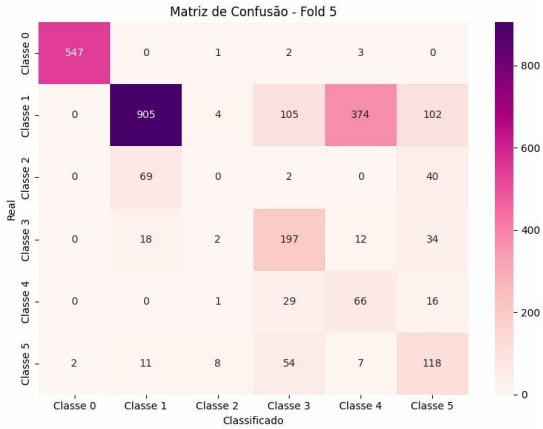

Figura 5. Matriz de confusão com os resultados obtidos no fold 5.

As matrizes de confusão apresentadas nas Figuras 1 a 5 ilustram visualmente o desempenho do classificador em cada uma das cinco iterações da validação cruzada. A diagonal principal, de cor mais escura, indica as classificações corretas. Observa-se um desempenho robusto para a Classe 0 (**non-lung**) em todos os cenários. Em contrapartida, a diagonal para

a Classe 2 (**enfisema**) é nula em todos os folds, indicando uma falha completa do modelo em identificar esta categoria. As demais classes apresentam um comportamento instável, com padrões de confusão recorrentes, especialmente entre as classes 1, 3 e 5, evidenciando a complexidade da tarefa de classificação.

IV. Análise dos Resultados

Para uma análise mais aprofundada, as métricas de classificação foram consolidadas por meio da média dos 5 folds, conforme detalhado na Tabela VI. A performance do modelo variou de forma significativa entre as diferentes classes.

A análise por classe revela três grupos de desempenho:

A. *Alto Desempenho*

A Classe 0 (**non-lung**) foi identificada com alta eficácia, alcançando um F1-Score de 0.98. Isso indica que as características de regiões fora do tecido pulmonar são facilmente separáveis para o modelo implementado.

B. *Desempenho Mediano*

As Classes 1 (**normal**), 3 (**vidro fosco**), 4 (**fibrose**) e 5 (**micronódulos**) apresentam um desempenho mediano, com F1-Scores variando de 0.62 a 0.69. Para a classe **normal**, a média para o recall foi superior à precisão, sugerindo que o modelo é mais propenso a classificar um padrão como **normal** do que a errar um caso verdadeiramente **normal**. O inverso ocorre com a classe **micronódulos**, que obteve uma média de F1-Score maior entre as classes patológicas, demonstrando uma capacidade considerável de distinção.

C. *Falha na Classificação*

A Classe 2 (**enfisema**) demonstrou uma falha completa de ser identificada, com precisão, reccall e F1-Score de 0.00. Apesar de a especificidade ser alta, isso apenas indica que o modelo raramente classifica falsamente outras classes como **enfisema**, mas crucialmente, ele nunca identifica corretamente um caso real de **enfisema**.

V. Discussão dos Resultados

A performance quase perfeita na Classe 0 (**non-lung**) era esperada, visto que as características de textura e intensidade de regiões de ar são trivialmente distintas do tecido pulmonar.

O ponto mais crítico dos resultados é a falha total na classificação da Classe 2 (**enfisema**). A análise do número de amostras em cada fold Tabelas I a V revela o motivo desse problema: um **desbalanceamento de classes**. A classe **enfisema** representa uma fração muito pequena do conjunto de dados, logo a distribuição de amostras por fold foi quase nula. Modelos baseados em distância como o KNN são sensíveis ao desbalanceamento, pois, durante a predição, é mais provável que os "vizinhos mais próximos"de qualquer amostra pertençam às classes que estão em maioria. Consequentemente, o modelo aprendeu a ignorar a classe minoritária, resultando em um recall nulo.

Para as demais classes, o desempenho moderado pode ser atribuído à alta similaridade entre suas características radiômicas. Isso gera uma sobreposição no espaço de características, dificultando a diferenciação entre os padrões de **vidro fosco**, **fibrose** e **micronódulos**. Além disso, o modelo exibiu um recall consistentemente superior à precisão. Tal comportamento indica que o classificador, em cenários de incerteza, tende a favorecer a classe mais representada nos dados de treino, priorizando a identificação de todos os casos verdadeiros ao custo de um maior número de falsos positivos.

VI. Conclusão

Este trabalho apresentou o desenvolvimento e a avaliação de um pipeline computacional totalmente automatizado para a classificação de padrões de tecido pulmonar em imagens de Tomografia Computadorizada, utilizando uma abordagem baseada em radiômica e o classificador K-Nearest Neighbors (KNN).

Os resultados demonstram a viabilidade da metodologia, na qual o modelo distinguiu com eficácia o tecido não pulmonar, com um F1-Score de 0.98. Contudo, a performance geral do classificador foi impactada por duas limitações principais: **(1)** uma falha na identificação da Classe 2, causada por um desbalanceamento no conjunto de dados, e **(2)** um desempenho apenas moderado nas demais classes, devido à alta similaridade e sobreposição das suas características radiômicas.

A principal conclusão é que, embora o pipeline automatizado seja funcional e a radiômica uma ferramenta promissora, o sucesso da classificação depende criticamente do balanceamento dos dados e da capacidade do algoritmo em lidar com características complexas e sobrepostas.

Como trabalhos futuros, sugere-se a aplicação de técnicas de balanceamento de dados para aumentar a representatividade das classes minoritárias. Além disso, a exploração de algoritmos de classificação mais robustos e a incorporação de métodos de seleção de características poderiam aprimorar a capacidade de distinção do modelo.

Apesar das limitações, o pipeline proposto estabelece uma base de referência valiosa e um framework totalmente automatizado para a análise de imagens pulmonares. O estudo valida a viabilidade da radiômica como ferramenta de classificação e aponta caminhos claros para o aprimoramento de futuros sistemas de diagnóstico auxiliado por computador.

Referências

[1] J. J. M. van Griethuysen, A. Fedorov, C. Parmar, A. Hosny, N. Aucoin, V. Narayan, R. G. H. Beets-Tan, J.-C. Fillon-Robin, S. Pieper, e H. J. W. L. Aerts, "Computational Radiomics System to Decode the Radiographic Phenotype," *Cancer Research*, vol. 77, no. 21, pp. e104–e107, 2017. doi: 10.1158/0008-5472.CAN-17-0339.

[2] S. Bhutani, "Otsu's Binarization," *LearnOpenCV*, 20 de maio de 2022. [Online]. Available: https://learnopencv.com/otsu-thresholding-with-opencv/. [Acessado em: 7 de junho de 2025].

[3] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, e E. Duchesnay, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.